




AI活用研修 第4回：ローカルLLM環境構築仕様書

「社外秘」を扱うための完全オフラインAI実行環境



TARGET AUDIENCE / 対象読者

- 開発担当A (Python / VS Code)
- 開発担当B (VB.NET / Visual Studio)




SCOPE / 範囲

- LM Studio Setup
- Llama 3.1 Integration
- Localhost API Routing



全体像：私たちが目指すAIシステムの組み立てライン



① 現場のデータ (原材料)

例：検査画像、ログファイル、
センサー値

② ONNXでAI判定 (精密エンジン)

OK/NG、異常ラベル、
確信度スコアなどを出力

③ RAGで社内 マニュアル検索 (部品カタログ)

(次回のテーマ) 判定結果に
関連する手順や仕様を検索

④ SK+LLMで 「わかる言葉」に変換 (中央制御・組立)


数値データを人間が理解で
きるレポート形式に整形

⑤ VB.NET/C# 業務アプリとして出荷 (完成品)

現場のPCで、誰でも使え
る形で提供


本日のミッション：インターネットからの切断

BEFORE / 現状 JetBrains Mono



前回作成したRAG用データには機密情報が含まれるため、外部APIへの送信ができない。

AFTER / 目標 JetBrains Mono



インターネット接続なしで、社外秘データを安全に処理する「自分たちだけのAI」を稼働させる。

MISSION: 完全にオフラインのPC内で、ChatGPT並みのAIを稼働させる。

DWG NO. OFF-AI-001 REV A
DATE: 2024-05-27
SCALE: NTS ENGINEER: T.SATO

システム構成概念図 (System Architecture)

Llama 3.1 8B (Model)

音楽CD / 脳みそ - 軽量化モデル (Q4_K_M)
mp3圧縮相当 (約5GB)

LM Studio (Software)

再生機 / 筐体 - 推論実行エンジン

RAG Data (Markdown)

歌詞カード / 参照情報 - 社外秘データ

KEY TAKEAWAY: プレイヤー (ソフト) にCD (モデル) をセットし、
歌詞カード (データ) を読ませる構成。

DWG NO.	REV
OFF-AI-002	A
DATE: 2024-05-27	SCALE: NTS
SCALE: NTS	ENGINEER: T. SATO

LM Studioの使い方について

<https://devlog.mescius.jp/lm-studio-introduction/>

Technical Specification & Performance Metrics

 **モデル名:**
Llama 3.1 8B Instruct

 **コンテキスト長:**
128K Tokens
(マニュアル1冊分)

 量子化 (Quantization):
Q4_K_M (圧縮率 約50%)

 **必要メモリ (VRAM):**
~6GB
(一般的なノートPCで動作可)




	8B (Selected)	70B	405B
パラメータ数	 80億 (8B)	 700億 (70B)	 4050億 (405B)
推奨ハードウェア	 Consumer GPU / CPU / CPU	 A100 / A6000	 H100 Cluster
用途	 エッジ・個人PC・ 高速応答	 サーバー・RAG・ 要約	 研究・複雑推論・ 蒸留

⚠️「GPT-4oに匹敵する知能を持つ405Bモデルの弟分。軽量ながら高度な日本語処理能力を保持。」

事前準備確認：資材チェックリスト

Material List

- ☐ LM Studio: インストール済
(Installed)
- ☐ モデルファイル: Llama 3.1 8B
Instruct (Q4_K_M) - ダウンロード済
JetBrains Mono
- ☐ 秘伝のタレ: 社外秘Markdown資料 -
作成済
JetBrains Mono



DRG NO. OFF-AI-003 REV A	
DATE: 2024-05-27	ENGINEER: T. SATO
SCALE: NTS	

Chats



Unnamed Chat ...

Add instructions

Unnamed Chat ...




こんにちは、あなたは誰ですか？

Send a message to the model...



実装フェーズ1：サーバー稼働手順

STEP 1: オフライン動作確認



通信なしで応答が返ることを確認
(完全オフライン)

STEP 2: サーバーモード起動



		DRS NO.
		OFF-AI-003 REV A
DATE:	SCALE:	ENGINEER:
2024-05-27	NTS	T. SATO



LM Studio



LM Runtimes



Select a model to load (Ctrl +L) ▾



Status: Running



Settings

Reachable at:

<http://192.168.0.90:1234>

Type to filter...

Your models

No

Gemma 3 12B Instruct

Q4_K_M



lmstudio-community

Nomic Embed Text v1.5

Q4_K_M

nomic-ai

Gemma 2 9B Instruct

Q4_K_M

lmstudio-community

Gemma 2 27B Instruct

Q4_K_M

lmstudio-community

DeepSeek R1 Distill Qwen 32B

Q4_K_M

lmstudio-community

DeepSeek R1 Distill Llama 8B

Q4_K_M

lmstudio-community

Supported endpoints (OpenAI-like)

Developer Logs

```
2025-03-22 13:42:44 [INFO] [LM STUDIO SERVER] -> POST
2025-03-22 13:42:44 [INFO] [LM STUDIO SERVER] -> POST
2025-03-22 13:42:44 [INFO] [LM STUDIO SERVER] -> POST http://192.168.0.90:1234/v1/embeddings
2025-03-22 13:42:44 [INFO]
2025-03-22 13:42:44 [INFO] [LM STUDIO SERVER] Logs are saved into C:\Users\vec00\cache\lm-studio\server-logs
```



Manually choose model load parameter

Semantic Kernelでの接続

VB.Net CONFIG

```
1
2
3  ' ローカルLLM (Llama 3.1) への接続設定
4  builder.AddOpenAIChatCompletion
5  builder.AddOpenAIChatCompletion(
6      modelId: "llama-3.1-8b-instruct", ' LM Studioで読み込んだ名前
7      apiKey: "not-needed",           ' ローカルなので何でもOK
8      endpoint: new Uri("http://localhost:1234/v1") ' ← ここが自分のPCの住所
9  )
10
```


Python CONFIG

```
1
2
3  # ローカルLLMへの接続設定
4  service = OpenAIChatCompletion(
5      ai_model_id="llama3.1",
6      api_key="ollama",
7      service_id="local-llm",
8      # ↓ ここでOllama/LM Studioのポートを指定します
9  )
10  # ※ライブラリのバージョンに合わせてURLを設定 (先ほどの実習通り)
```

POINT: 接続先を書き換えるのみ。Semantic Kernelを使えば、相手がOpenAIでもローカルLLMでも、プログラムは騙されたまま動く。

VERIFICATION: プログラムを実行し、LM Studio側の緑のログが動けば「脳みそのジャック」成功。

RAG知識注入プロセス



Q: エラー502

	一般的なAI (Cloud)	
	「サーバーを再起動しましょう (502エラーの一般的な対処)」	RISK: 現場停止
	今回のローカルAI (RAG)	
	「待て！再起動は触壁だ。DefOneAgentをタスクキルしろ！」	RESULT: 正解 (社内ルール遵守)

POINT: ネット上の正論ではなく「御社だけの泥臭い正解」を回答。
深夜にベテランを叩き起こす必要はもうない。

ORG. NO. OFF-AI-001 REV A
DATE: 2024-05-27
SCALE: NTS DECIMBER: T. SATO

講師が読み込ませた「秘伝のタレ」

社内システム開発・運用ナレッジ（社外秘）

1. レガシーコード解説：生産管理システム(旧)

- ****対象****: VB.NET製 `OrderManager.dll` / `T\_ORDER` テーブル

- ****隠された仕様****:

- カラム `DEL\_FLG` は削除フラグではない。実は「配送(Delivery)済みフラグ」。

- ****削除済みデータ****は、なぜか `MEMO` 欄に「DELETE」という文字列が入っているレコードを指す(2015年の仕様変更時の負の遺産)。

- ****警告****: `WHERE DEL\_FLG = 1` で削除データを検索しようとすると、配送済みデータがヒットして請求ミスになる。絶対に触るな。

2. トラブルシューティング：顧客サーバーA (AWS)

- ****事象****: HTTP 502 Bad Gatewayが深夜に多発する。

- ****真の原因****:

- ログにはメモリ不足と出るが、本当の原因はウイルス対策ソフト`DefenseOne`の競合。

- 特定のTempファイルをロックしてしまい、IISがタイムアウトしている。

- ****対処法（再起動厳禁）****:

1. サーバー再起動は****絶対にしてはならない****（DBの整合性チェックが走り、朝まで復旧しなくなる）。

2. まずタスクキルで `DefOneAgent.exe` を落とす。

3. `C:\App\Unlocker.bat` を管理者権限で実行し、共有メモリを解放する。

4. これで502は自然解消する。

3. 独自ライブラリ: `MyCorp.Common.Log`

- ****クラス****: `AsyncLogger`

- ****既知のバグ****:


- メソッド `Write()` はスレッドセーフではない。

- ****制約****: マルチスレッド処理（`Parallel.ForEach`など）の中から呼ぶと、稀にデッドロックしてアプリが固まる。

- ****回避策****: 必ず `lock` ステートメントで囲って呼び出すこと。

なぜこの内容にしたかの根拠

根拠1 / 一般的知識の誤謬 (DEL_FLG)



一般的なAIは「削除フラグ」と誤認識。
→ 社外秘仕様「DEL_FLG=配送済み」を教え込まないと、請求ミス等の深刻な事故が発生する。

根拠3 / 独自ライブラリの地雷 (AsyncLogger)


AWS 公式マニュアルにはない「再起動厳禁」「ウイルス対策ソフト」に起因という予見する。
→ デッドロックの長時間停止を回避にする。

根拠2 / 属人的トラブル解決 (サーバー再起動厳禁)



AWS公式マニュアルにはない「再起動厳禁」「ウイルス対策ソフトが原因」という情報は、社内ナレッジにしかない。
→ 再起動による長時間停止を回避する。

根拠3 / 独自ライブラリの地雷 (AsyncLogger)




自社製ライブラリのバグ「スレッドセーフでない」は、コードやナレッジを与えない限り予見不可。
→ デッドロックの危険なコード生成を未然に防ぐ。

MISSION: 完全にオフラインのPC内で、ChatGPT並みのAIを稼働させる。

DWG NO.	OFF-AI-801 REV A
DATE:	2824-85-27
SCALE	NTS
ENGINEER:	T. SATO

ローカルLLMの「弱点」とチューニング



課題

- ・速度 (PCスペック依存)
- ・指示の無視
- ・日本語の怪しさ

解決策

ROLE A (**Python**): プロンプトエンジニアリングで補強 (曖昧な指示を排除、Few-shotなど)。

ROLE B (**VB.NET**): プログラム側でリカバリ処理 (JSONエラー時の再試行ロジック) を実装。

GPT-4は8Bパラメータの100倍以上のサイズ

最終課題 最終課題：業務改善プロトタイプ策定

1. 課題

『半径5メートル』の困りごとを特定せよ。

例：日報入力が面倒 / 仕様確認で作業が止まる

2. 解決策・エンジン選定

- ☐ ローカルLLM？
(社外秘データあり)
- ☐ GPT？
(精度優先・公開データ)

3. アプリ仕様

実装形態を選択:

VB.NETの画面？

既存システムのボタンに追加？

Webアプリ？

LIMIT: 20 MIN

ディスカッション：『壮大なDX』を目指さなくてOK。『半径5メートルの、具体的で泥臭いと』の方が、AI導入は成功しやすい。 ローカルLLMは『狭く深い知識』が得意。

DWG NO. OFF-AI-001 REV A

DWG. 2824-05-27

SCALE: NTS

ENGINEER: T. SATO

研修受講前後の変化について

第1層：行動・事実（外側）

- 研修前と後で、触るツールはどう変わりましたか
- 実際に作ったもの・試したものは何ですか
- RAGやローカルLLMで一番時間を使った工程はどこですか
- 業務の中でAIを使った回数は増えましたか
- 使い方が変わった具体例はありますか

第2層：認識の変化（内側の手前）

- 研修前後で、AIに対する認識はどう変わりましたか
- 一番ギャップが大きかった学びは何ですか
- 「ここは誤解していた」と思ったポイントはありますか
- エンジニアとしての役割は変わりましたか

第3層：意味・未来（核心）

- この技術を使うことで、自分の仕事はどう変わりそうですか
- 会社の開発体制にどんな影響が出ると思いますか
- 1年後、自分の市場価値はどう変わるとと思いますか
- 「できるようになったこと」で誰が助かりますか
- 今後、どんなプロダクトを作りたいですか

DOC. NO. OFF-AI-001 REV. A

DATE 2024-05-27

NTS

T. SATO